CONTENT SOURCING & M0 SCOPE

内容不是找不到
是「讲解」必须自己写

法语例句、变位、母语音频、语法大纲——这些网上确实都有，而且有相当一部分是开放许可的。 但面向中文母语者的「讲解」几乎不存在可复用的开放语料。这份文档把可获取的部分、必须自写的部分、 以及 M0 到底做多少，一次说清楚。

调研日期	核验来源	M0 周期	M0 内容量
2026-10-18	14 个	5 天	20 知识点 / 160 题

00 结论先行

三句话，决定后面所有事。

可以白拿的

70%

法语例句（Tatoeba，CC BY）、母语音频（FSI 公版 / Common Voice CC0 / Français interactif CC BY）、动词变位（verbecc）、语法大纲（Wikibooks CC BY-SA）。

必须自己写的

30%

中文讲解、中国人易错点、干扰项设计、题目与知识点的对应关系。这部分没有任何开放语料可以直接搬。

绝对不能碰的

0

Kwiziq / Lawless French 的课文与题库、TV5Monde、RFI、Duolingo、沪江/法语角等版权保留内容。

最关键的判断：你担心的「音频和讲解」其实是两类完全不同的东西。音频是**工程问题**——用本地 TTS 批量生成，2 秒一条，零版权风险，M0 阶段就能全量覆盖。讲解是**写作问题**——但它比想象中便宜：一个知识点只需要 **120 字规则 + 2 组对比例句 + 1 条易错点**，熟练后 8–10 分钟一个。

所以真正的成本不是「找内容」，而是「把法语素材对齐到知识点，并用中文重写一遍」。这条流水线我已经搭出可运行的骨架（见第五节与 `tools/`）。

另一个必须先纠正的预期：**不存在「下载一个包就拥有 500 个知识点」的捷径。**开放教材（如 Français interactif）是**按课**组织的，不是按「可独立测试的规则」组织的。从教材到知识点，中间必须做一次拆解——这正是 6.1 节说的 45–55 人日里最花时间的部分，也是产品差异化的来源。

01 来源矩阵

14 个来源，按「能不能直接用」排序。

来源	提供什么	许可	怎么用
Français interactif UT Austin / COERLL	13 章零基础课程、320+ 视频、词汇与语音音频、语法参考 + 自测练习、音频对话、变位工具	CC BY 4.0	**首选。**可改编、可商用，只需署名。语法页可作讲解骨架，音频对话可做听力素材。
Tatoeba	数百万条例句，含中文翻译；部分句子有母语者录音；公开 API	文本 CC BY 2.0 FR 音频逐条不同	**例句主力。**按关键词/句型检索，挑「有中文翻译 + 长度合适」的句子，改写后入库。音频不要直接用。
FSI French Basic Course	完整 PDF 教材 + 数十小时母语录音（对话、drill）	PUBLIC DOMAIN	美国政府作品，无任何限制。内容较老（1960s），适合做听力素材与句型库，不适合做当代口语示例。
Piper TTS	本地神经 TTS，7 个法语声音（siwis / mls / upmc / tom / gilles）	代码 MIT SIWIS/MLS: CC BY 4.0	**音频主力。**离线批量生成 wav，声音一致、零版权风险。默认用 `fr_FR-siwis-medium`。
Kokoro-82M	82M 参数多语 TTS，含 fr-fr 声音，自然度优于 Piper	APACHE 2.0	备选。CPU 也能跑，适合对音质要求更高的例句；生成速度慢于 Piper。
Common Voice Mozilla	法语朗读语音（Scripted Speech 27.0 法语包约 28.55 GB）	CC0	无任何限制。但句子不对齐语法点，适合做「辨音/听写」素材，不适合做例句音频。
Wikibooks French	按级别组织的语法大纲（形容词、副词、冠词、代词、动词时态…）	CC BY-SA	**只做清单参考**，不要整段改写。事实与标题不受版权保护，表达受保护。
Wiktionnaire	释义、变位表、音标、部分发音	CC BY-SA	校对用（查一个动词的变位对不对），不要批量搬运表格，避免 ShareAlike 传染。
verbecc	法语动词完整变位（全部语式/时态/人称），数千动词 + 未登录词预测	LGPLV3	作为**库**调用生成变位题与答案校验；不要把它的源码嵌进闭源部分。
Lexique 4	19 万词形的词频、音标、词形、词素结构	CC BY-SA 4.0 页面链接含 NC，需复核	用于「这个词常不常用」的难度校准，以及词汇表排序。非必需。
Lingua Libre	社区录制的单词/短语发音，法语量大	CC BY-SA 4.0	单词级发音补充（如「这个词怎么读」按钮），不做整句。
LibriVox / Gutenberg	公版法语有声书与文本	PUBLIC DOMAIN	B1 以上的泛读/泛听素材，后续版本再用。
Verbiste	法语变位模板 XML（verbecc 的上游）	GPL	仅作参考。GPL 传染性强，不直接嵌入。
Kwiziq / Lawless French TV5Monde / RFI / Duolingo	课文、题库、讲解、音频、视频	版权保留	**只可人工阅读参考，不可抓取、翻译、改写、复用。**包括「换几个词」的洗稿。

许可信息以各站点 2026-10-18 的公开页面为准。CC BY-SA 类来源只做「查证」与「清单参考」，避免衍生作品被要求同许可。

02 五层内容策略

一个知识点由五种材料组成，每种材料的获取方式完全不同。

① 大纲层	知识点清单、级别、先修关系	自建（参考 Wikibooks / CEFR）
② 素材层	法语句子、对话、短文	Tatoeba / FI / FSI（开放）
③ 音频层	例句朗读、听写音频	Piper / Kokoro 本地生成
④ 讲解放层	中文规则、对比、易错点	100% 自写（LLM 起草 + 人工审）
⑤ 题目层	题干、答案、干扰项、解析	自建（可用 verbecc 校验）

图 1 · 越往下越难外包：大纲和素材可以找，讲解和题目必须自己造

层	获取方式	自动化程度	说明
① 大纲	人工整理 + LLM 辅助	半自动	从公开语法目录提取主题，按「可独立测试」拆成 320 条，再标级别与先修。事实性清单不受版权保护。
② 素材	Tatoeba API 检索 + 人工挑选	可脚本化	按句型正则检索，过滤长度、语域、翻译质量。候选 20 条里挑 3 条，再改写。
③ 音频	Piper 批量合成	全自动	输入 JSON，输出 `tts/fr/{kp_id}/{n}.wav`。一条约 0.5–2 秒。
④ 讲解	模板 + LLM 起草 + 人工定稿	半自动	固定三槽位：一句话规则 / 2 组对比 / 1 条易错。LLM 只能起草，必须人工核对语法与中文表达。
⑤ 题目	模板 + 人工设计干扰项	手工	干扰项必须来自真实错误（如 *est parti），不能随机替换。这是题目质量的分水岭。

为什么不用 LLM 直接生成全部内容？ 可以生成 80% 的初稿，但法语语法细节（性数配合、介词、语域）错误率不低，而语言学习产品对错误的容忍度是零——教错一次，用户会记很久。正确用法是：**LLM 起草 + 规则校验（verbecc/拼写）+ 人工抽检 100% 的 primer 与 20% 的题目。**

03 重点来源实测

不是「听说有」，是「我调通了」。

① Tatoeba：例句 + 中文翻译，API 可直接用 已验证

实测请求：检索包含 `n'ai pas de` 的法语例句，要求有中文翻译，返回 **153 条**；每条都带许可字段、翻译分组、音频列表。

```
GET https://tatoeba.org/en/api_v0/search
    ?from=fra&to=cmn&query=n%27ai%20pas%20de&sort=relevance

// 返回（节选）
{
  "text": "Je n'ai pas de livre.",
  "license": "CC BY 2.0 FR",
  "audios": [],
  "translations": [[{ "text": "我没有书。", "lang": "cmn" }]]
}
```

这解决了两件最难的事：**地道的法语句子**和**现成的中文翻译**。但有两个坑：

- **音频许可不在 API 里。**实测 `audios[].license` 返回 `null`，必须去贡献者主页逐条确认。所以**不要用 Tatoeba 的音频**，改用 TTS。
- **翻译不一定贴题。**「Bonjour」有「你好 / 下午好 / 早上好」三种译法，必须人工挑一个与例句语境匹配的。

② Français interactif：唯一「课程 + 音频 + 语法 + 练习」全齐的开放教材 CC BY

COERLL 官方描述：13 章第一年法语课程，含 **320+ 视频**、词汇与语音音频、在线语法参考 + 自校正练习、音频对话、变位工具。许可为 **CC BY**（可改编、可商用、需署名）。

它的价值不在于「直接抄」，而在于三点：**语法页的结构可以照着重写**（规则 → 对比例句 → 练习），**音频对话可以做听力题**，**章节顺序可以作为 A0–A1 的先修依据。**

③ FSI：公版，但别指望它现代 PUBLIC DOMAIN

FSI 法语基础课程是 1960 年代为美国外交官开发的，PDF + 数十小时母语录音，**美国政府作品，公版。**优点是句型密度高、drill 设计严谨；缺点是语料老旧（telephone、cassette 之类的场景），且以英语为母语者设计。适合做**听力素材库**，不适合做产品的主例句。

④ 音频：Piper 是当前最稳的本地方案 已验证声音清单

声音	质量	许可	结论
`fr_FR-siwis-medium`	medium	CC BY 4.0	**默认。**单说话人、清晰、许可干净
`fr_FR-mls-medium`	medium	CC BY 4.0	125 个说话人，可做「换个人读」的听力变体
`fr_FR-upmc-medium`	medium	CC BY-SA 4.0	可用，但 ShareAlike 有解释成本，非首选
`fr_FR-tom-medium`	medium	AGPLV3	**不用。**传染性许可
`fr_FR-gilles-low`	low	—	音质不足，不用

另：Kokoro-82M（Apache 2.0）含 fr-fr 声音，自然度更好，可作为 B 方案；Common Voice（CC0）适合做真实人声的听写素材。

⑤ 变位：verbecc 生成，不搬维基 LGPL

verbecc 支持数千法语动词的完整变位（含复合时态、代词式动词、阴/阳性第三人称），并能用机器学习预测未登录词（约 99% 准确）。作为库调用即可，避免从 Wiktionnaire 批量搬表带来的 CC BY-SA 传染。

04 版权边界

四档，越往下越危险。

档位	含义	典型来源与做法
A 自由使用	公版或 CC0，无署名义务	FSI、Gutenberg、LibriVox、Common Voice。可任意改写、商用。
B 署名可用	CC BY，可改编商用，需在「关于」页署名	Français interactif、Tatoeba 文本、Piper siwis/mls 声音。产品里放一个「内容来源」页，列出来源、作者、许可链接。
C 只查证不搬运	CC BY-SA / LGPL，直接改编会触发同许可	Wikibooks、Wiktionnaire、Lexique。用来核对规则与变位，不整段复制。verbecc 作为库调用。
D 不可用	版权保留，任何形式的复制/翻译/洗稿都侵权	Kwiziq、Lawless French、TV5Monde、RFI、Duolingo、沪江、法语角。只能人工阅读后用自己的话重写，且不能照搬例句结构。

三个容易踩的坑：

① **「换几个词」不算原创。**把 Kwiziq 的例句改两个词，仍然可能构成演绎侵权。

② **CC BY-SA 会传染。**如果把 Wikibooks 的段落改写进你的讲解，那段讲解可能需要以 CC BY-SA 发布。规避方式：只提取「讲什么」，不提取「怎么讲」。

③ **Tatoeba 音频许可不明。**API 不返回许可，逐条确认成本极高。统一用 TTS，既干净又一致。

05 内容管线

七步，从「一个语法主题」到「可入库的知识点」。



图 2 · 内容管线：只有 2、6、7 能全自动，1、3、4、5 是人的工作

管线已经落到仓库里：

```
content/
├─ sources.json          # 来源注册表：URL / 许可 / 用途 / 署名文本
├─ schema/kp.schema.json # 知识点 JSON Schema
└─ kp/*.json             # 每个知识点一个文件
tools/
├─ fetch_tatoeba.py      # 按句型检索候选例句（含中文翻译）
├─ tts_piper.py          # 批量合成例句音频
└─ validate_content.py   # schema + 引用完整性校验
```

实测：一条命令拿到候选例句

```
$ python tools/fetch_tatoeba.py --query "n'ai pas de" --limit 8

  1. Je n'ai pas de livre.                    我没有书。          [audio: no]
  2. Je n'ai pas de temps.                    我没有时间。        [audio: no]
  3. Il n'y a pas de problème.                没问题。            [audio: no]
  ...
  # 输出 content/candidates/negation_ne_pas.json，含 id / 许可 / 翻译 / 音频标记
```

这个脚本只做「候选收集」，不做自动入库——因为例句是否贴题、翻译是否自然，必须人看。工具的价值是把 30 分钟的手工搜索压到 30 秒。

06 单点生产 SOP

一个知识点从空白到可上线，标准工时 25–35 分钟。

步	动作	工时	产出 / 标准
1	写 ID、级别、标题、先修	2 min	`fr.a1.negation.ne_pas`；先修至少 1 条
2	写 primer 三槽位	8 min	规则 ≤ 60 字；对比 2 组；易错 1 条（必须是中国人会犯的）
3	检索并挑选例句	5 min	2–4 条，长度 4–12 词，语域为日常
4	写 8 道题	12 min	2 单选 + 4 填空 + 1 改错 + 1 翻译；每题有解析
5	合成音频	1 min	每条例句 1 个 wav，命名 `{kp_id}-ex{n}.wav`
6	校验	2 min	schema 通过；变位正确；答案唯一（或有 accept 列表）
7	抽检	3 min	换一个人（或隔天自己）盲做 3 题，能全对才算过

按 30 分钟 / 点计算：**20 点 ≈ 10 小时（约 1.5 个工作日）**；320 点 ≈ 160 小时（约 20 个工作日）——比 6.1 节估计的 45–55 人日更低，因为例句和音频被工具省掉了。这是本次调研带来的最大成本修正。

> **成本重估：**原方案按「全手工写例句 + 录/找音频」估 45–55 人日；引入 Tatoeba + Piper 后，例句与音频几乎零成本，**320 个知识点的内容成本降到约 20–25 人日。**M0 的 20 个点可以在 1.5 天内完成。

07 M0 范围

5 天，只证明一件事：机制跑得通，内容造得出。

M0 的成功标准不是「好看」，而是：拿 20 个真实知识点，走完一次完整的「学 → 测 → 评分 → 重排」，并且分数曲线符合直觉。

模块	做	不做（留给 M1+）
内容	20 个知识点（A0 8 / A1 7 / A2L 5），每点 1 段 primer + 8 题 + 2–4 条例句 + 音频，共 160 题	不追 320 点；不做 B1 以上；不做阅读理解
数据	JSON Schema、SQLite 建表、seed 导入、全量导出	不做增量同步、不做多用户
引擎	BKT 更新、展示分（含负分与收缩）、FSRS 调度、10 题组卷（配额 + 打分 + 约束）、预学习状态机	不做 Elo 题目校准；不做级别分稀释的可视化
界面	3 页：Dashboard（静态）、Kwiz Runner（作答 + 即时反馈）、结果页（逐题对照）	不做 Brainmap、分级测试、Notebook、成就、通知、Tauri 打包
工具	Tatoeba 抓取、Piper 合成、内容校验三个脚本	不做后台管理界面

验收清单（5 条，缺一不可）

#	标准	验证方式
1	20 个 KP 全部通过 schema 校验，无悬空先修引用	`python tools/validate_content.py`
2	160 道题答案与解析齐全；法语变位经 verbecc 校验	校验脚本 + 人工抽检 20%
3	固定随机种子下，同一作答序列产生同一分数曲线	Vitest 快照测试
4	一次 10 题覆盖 ≥ 4 个知识点，难度整体上行，无最近重复题	组卷单测（100 次随机运行断言）
5	三页可完整走通；刷新/重启后进度不丢	手动走查 + Playwright 冒烟

5 天排期

天	工程	内容
D1	monorepo、SQLite schema、seed 脚本	20 个 KP 清单（ID / 级别 / 先修）
D2	engine：BKT + 展示分 + 单测	前 10 个点的 primer + 例句
D3	engine：FSRS + 组卷 + 单测	后 10 个点 + 全部 160 题
D4	API + Kwiz Runner + 结果页	音频批量合成 + 抽检
D5	Dashboard + 联调 + 冒烟测试	校验脚本全绿 + 盲做验收

如果只有 3 天：砍到 10 个知识点 / 80 题，只做 Kwiz Runner + 结果页，Dashboard 用一张静态页代替。机制验证不需要 20 个点，10 个就够看出分数手感对不对。

08 风险与决策

开工前需要你拍板的三件事。

风险	等级	对策
Tatoeba 例句质量参差	中	只取「有中文翻译 + 长度 4–12 词 + 无脏话标签」的句子，再人工改写；不追求数量。
TTS 发音不准（联诵、省音）	中	Piper 对短句表现好；对含联诵的句子人工试听，必要时换 Kokoro 或改写句子。
LLM 起草的讲解有语法错误	高	讲解必须人工定稿；用 verbecc + 拼写检查做机器校验；建立「已审」标记，未审不得入库。
CC BY-SA 传染	中	Wikibooks/Wiktionnaire 只查证不搬运；所有入库内容在 sources.json 记录来源与许可。
20 个点撑不起「像 Kwiziq」的感觉	中	M0 只验证机制，不验证内容丰富度；Brainmap 留到 M2，避免用 20 个点画出稀疏地图。

需要你拍板

决策点	选项	我的建议
M0 内容量	20 点 / 10 点	**20 点。**10 点不够覆盖 4 个功能块的组卷约束，会测不出问题。
音频方案	Piper / Kokoro / 真人录音	**Piper siwis。**先跑通，M2 再评估是否换 Kokoro 提升自然度。
是否引入 LLM 起草	全人工 / LLM 起草 + 人工定稿	**LLM 起草 + 人工定稿。**但讲解必须 100% 人工过一遍，不能省。

下一步：你确认 M0 范围后，我直接开始搭脚手架——先做 engine 的 BKT + 展示分，用 20 个点的真实数据跑出第一条分数曲线。这条曲线像不像 Kwiziq，决定了后面所有页面值不值得做。

内容来源调研与 M0 范围 · v1.0 · 2026-10-18

配套文件：`content/sources.json`（来源注册表）、`content/schema/kp.schema.json`、`tools/fetch_tatoeba.py`